

Multi-hop: $q(x_t|x_0) = N(x_t; \sqrt{\alpha_t} x_0, (1-\alpha_t)I)$
forward
where $\alpha_t = \prod_{s=1}^t \beta_s$, $\beta_s = 1-\alpha_s$

DDIM에서는 α_t 를 d_t 라고 적는다.

$q(x_t|x_0) = N(x_t; \sqrt{d_t} x_0, (1-d_t)I)$ (4)


$x_t = \sqrt{d_t} x_0 + \sqrt{1-d_t} \epsilon$, $\epsilon \sim N(0, I)$ 이 같이 적을 수 있다.
그리고 $d_t \rightarrow d_1, d_2, \dots$ 이 decreasing sequence 이다. $d_1, \dots \in [0, 1]$

DDPM에서 learning objective 는 다음과 같다.

$\mathcal{L}_r(\epsilon) = \sum_{t=1}^T \frac{1}{\beta_t} \mathbb{E}_{x_0 \sim q(x_0), \epsilon \sim N(0, I)} [\| \Sigma_t^{(0)}(\sqrt{d_t} x_0 + \sqrt{1-d_t} \epsilon) - \epsilon \|_2^2]$ (5)
same constant, depends on d_t .
(DDPM에서는 $d_t=1$ 이 된다)

(*) 여기서 $q(x_{1:T}|x_0)$ 의 joint를 고려하는 것이 아니라, $q(x_t|x_0)$ 의 multi-hop marginal distribution 만이 depend 한다. 그래서 여러 joint distribution 들의 하위의 marginal distribution 이 대응된다. DDIM에서는 $q(x_t|x_0)$ 를 다루고 있는 다른 marginal $q_0(x_{1:T}|x_0)$ 를 제안한다!

$q_0(x_{1:T}|x_0) = q_0(x_T|x_0) \prod_{t=2}^T q_0(x_t|x_{t-1}, x_0)$
multi-hop
 $q_0(x_t|x_0) = N(x_t; \sqrt{d_t} x_0, (1-d_t)I)$
이걸 원래처럼 적는다.



$q_0(x_{t-1}|x_t, x_0) = N(x_{t-1}; \sqrt{d_{t-1}} x_0 + \sqrt{1-d_{t-1}-d_t} \frac{x_t - \sqrt{d_t} x_0}{\sqrt{1-d_t}}, \alpha_t I)$ (7)

(7) 이 식은 $q_0(x_{t-1}|x_t, x_0)$ 로 적히는 $q_0(x_{1:T}|x_0)$ 의 marginal 인 $q_0(x_t|x_0)$ 로 적히는 $N(x_t; \sqrt{d_t} x_0, (1-d_t)I)$ 로 적히는 DDPM의 marginal과 똑같이 적히는 식을 쓴 것이다.

그리고 이렇게 구해진 $q_0(x_{t-1}|x_t, x_0)$ 를 이용하여 forward도 적을 수 있다.

$q_0(x_t|x_{t-1}, x_0) = \frac{q_0(x_{t-1}|x_t, x_0) q_0(x_t|x_0)}{q_0(x_{t-1}|x_0)}$ (8)
사실 제안한 것

그리고 (7)과 (8) 모두 β_t 를 통해서 stochastic으로 적을 수 있다. 즉, $\beta_t \rightarrow 0$ 이 되면 deterministic 하게 할 수 있다.

Generative process & unified variational inference

Trainable generative process $P_0(x_{0:T})$ where each $P_0^{(t)}(x_{t-1}|x_t)$ leverages knowledge of $q_0(x_{t-1}|x_t, x_0)$, \leftarrow (7)번 식!

작은 β_t 로 만든 $P_0^{(t)}(x_{t-1}|x_t)$ 를 활용하기 위해서

1. x_t 가 주어지면,
2. x_t 에서부터 대응되는 x_0 를 구하고, (원본 이미지) \leftarrow 이게 가능하냐?
3. 예측된 x_0 과 주어진 x_t 로부터 x_{t-1} 를 sample 한다. using $q_0(x_{t-1}|x_t, x_0)$

이렇게 하면 (9)인 $x_t = \sqrt{d_t} x_0 + \sqrt{1-d_t} \epsilon$ 를 사용한다.
 $\rightarrow x_0 = (x_t - \sqrt{1-d_t} \epsilon) / \sqrt{d_t}$ 이 관계가 되고, DDPM에서는 ϵ 를 $\Sigma_t^{(0)}(x_t)$ 로 적을 수 있고, x_0 의 예측을 $f_0^{(t)}(x_t)$ 라고 적는다.

$f_0^{(t)}(x_t) \approx (x_t - \sqrt{1-d_t} \Sigma_t^{(0)}(x_t)) / \sqrt{d_t}$ (9)
이 $\Sigma_t^{(0)}(x_t)$ 는 DDPM의 코디나 같다!

이제 바탕으로 다음의 generative process를 정의한다.

$P_0^{(t)}(x_{t-1}|x_t) = \begin{cases} N(f_0^{(0)}(x_0), \beta_1^2 I) & t=1 \\ q_0(x_{t-1}|x_t, f_0^{(t)}(x_t)) & \text{otherwise} \end{cases}$ (10)
(7)

(t=1) has $\beta_1^2 I$ to ensure that the generative process is supported everywhere.

VI objective becomes

$J_0(\epsilon) = \mathbb{E}_{x_{0:T} \sim q_0(x_{0:T})} [\log q_0(x_{1:T}|x_0) - \log P_0(x_{0:T})]$
 $\approx D_{KL}(q_0(x_{1:T}|x_0) \| P_0(x_{1:T}|x_0))$ * $D_{KL}(P||Q) = \int p \log \frac{p}{q}$
 $= \mathbb{E}_{x_{0:T} \sim q_0(x_{0:T})} [\log q_0(x_{1:T}|x_0) + \sum_{t=1}^T \log q_0(x_{t-1}|x_t, x_0) - \sum_{t=1}^T \log P_0^{(t)}(x_{t-1}|x_t) - \log P_0(x_T)]$ (11)

이 논문은 Theorem 1이 말하는 것은 (11)의 $J_0(\epsilon)$ 가 DDPM의 objective인 (5)와 같은 결과를 내는 것이다.

$\rightarrow L_1$ objective in DDPM can be used as a surrogate objective for the Variational objective J_0 as well!!

We can essentially use pretrained DDPM models as the solutions to the new objectives, and focus on finding a generative process that is better at producing samples subject to our needs by changing δ .

• Denoising Diffusion Implicit Models (DDIM)

$$p_{\theta}^{(k)}(x_{t+1}|x_t) = \begin{cases} N(x_t; f_{\theta}^{(k)}(x_t), \sigma_t^2 I) & t=1 \\ q_{\theta}(x_{t+1}|x_t, f_{\theta}^{(k)}(x_t)) & \text{otherwise} \end{cases} \quad (10)$$

$$\text{즉, } q_{\theta}(x_{t+1}|x_t, x_0) = N(x_{t+1}; \sqrt{\alpha_{t+1}}(x_0 + \sqrt{1-\alpha_{t+1}-\beta_t} \frac{x_t - \sqrt{\alpha_t} x_0}{\sqrt{1-\alpha_t}}), \sigma_t^2 I) \quad (11)$$

$$f_{\theta}^{(k)}(x_t) = \frac{(x_t - \sqrt{1-\alpha_t} \Sigma_{\theta}^{(k)}(x_t))}{\sqrt{\beta_t}} \quad (9)$$

이것들을 조합하면,


$$q_{\theta}(x_{t+1}|x_t, f_{\theta}^{(k)}(x_t)) = N\left(x_{t+1}; \sqrt{\alpha_{t+1}} \left(\frac{x_t - \sqrt{1-\alpha_t} \Sigma_{\theta}^{(k)}(x_t)}{\sqrt{\beta_t}} + \sqrt{1-\alpha_{t+1}-\beta_t} \frac{(x_t - \sqrt{\alpha_t} \Sigma_{\theta}^{(k)}(x_t))}{\sqrt{\beta_t}} \right), \sigma_t^2 I\right)$$

$$= N\left(x_{t+1}; \underbrace{\sqrt{\alpha_{t+1}} \left(\frac{x_t - \sqrt{1-\alpha_t} \Sigma_{\theta}^{(k)}(x_t)}{\sqrt{\beta_t}} \right)}_{\text{predicted } x_0} + \underbrace{\sqrt{1-\alpha_{t+1}-\beta_t} \Sigma_{\theta}^{(k)}(x_t)}_{\text{direction pointing to } x_{t+1}(\theta)}, \sigma_t^2 I\right)$$

$$\Rightarrow x_{t+1} = \sqrt{\alpha_{t+1}} \left(\frac{x_t - \sqrt{1-\alpha_t} \Sigma_{\theta}^{(k)}(x_t)}{\sqrt{\beta_t}} \right) + \sqrt{1-\alpha_{t+1}-\beta_t} \Sigma_{\theta}^{(k)}(x_t) + \sigma_t \epsilon_t$$

when $\sigma_t = \sqrt{\frac{1-\alpha_{t+1}}{1-\alpha_t}}$, DDIM becomes a DDPM. $\epsilon_t \sim N(0, I)$

• Accelerated Generation Process



$T=3, [1, 2, 3], \tau = [1, 3], 2 \text{ is missing. } \bar{\tau} = [2]$

$p_{\theta}(x_1|x_3) \approx$ 어떻게 찾아?

$$p_{\theta, \tau}(x_{1:3} | x_0) = p_{\theta, \tau}(x_3 | x_0) \prod_{t=2}^3 q_{\theta, \tau}(x_{t-1} | x_t, x_0) \prod_{t \in \bar{\tau}} q_{\theta, \tau}(x_t | x_0)$$

$$= p_{\theta, \tau}(x_3 | x_0) \left(q_{\theta, \tau}(x_1 | x_3, x_0) \right) q_{\theta, \tau}(x_2 | x_0)$$

The multi-hop is defined as: $q_{\theta, \tau}(x_t | x_0) \approx N(x_t; \sqrt{\alpha_t} x_0, (1-\alpha_t) I)$ \uparrow 이걸과 같게

$$q_{\theta, \tau}(x_{t+1} | x_{t+1}, x_0) \approx N(x_{t+1}; \sqrt{\alpha_{t+1}} x_0 + \sqrt{1-\alpha_{t+1}-\beta_t} \frac{x_t - \sqrt{\alpha_t} x_0}{\sqrt{1-\alpha_t}}, \sigma_t^2 I) \quad (12)$$

The corresponding "generative process" is defined as:

$$p_{\theta}(x_{0:T}) = \underbrace{p_{\theta}(x_T)}_{\text{Gaussian prior}} \underbrace{\prod_{t=1}^T p_{\theta}^{(\tau)}(x_{t-1} | x_t)}_{\text{reverse}} \times \underbrace{\prod_{t \in \bar{\tau}} p_{\theta}^{(k)}(x_0 | x_t)}_{\text{variational objective (2)}}$$

$$p_{\theta}^{(\tau)}(x_{t+1} | x_t) = q_{\theta, \tau}(x_{t+1} | x_t, f_{\theta}^{(\tau)}(x_t)) \quad (13)$$

(13)에 x_0 대신에 $f_{\theta}^{(\tau)}(x_t)$ 를 넣는다.

$$p_{\theta}^{(k)}(x_0 | x_t) = N(x_0; f_{\theta}^{(k)}(x_t), \sigma_t^2 I) \quad (13')$$

(13')는 실제 ancestral sampling 이 사용된다. (13)은 사용되지 않는다.